"SCALING & AUTOSCALING"



El siguiente documento detallará el paso a paso, el manejo del: **SCALING & AUTOSCALING** de los **CONTENEDORES** en **OPENSHIFT**. La **AGENDA** que se manejará será la siguiente:

- ✓ REQUERIMIENTOS.
- ✓ ESCALAMIENTO DE 'CONTENEDORES'.
 - SCALING INSTANCES.
 - HORIZONTAL AUTOSCALING INSTANCES.

DESCRIPCIÓN	DETALLE
1. REQUERIMIENTOS:	
El único requerimiento es tener <i>INSTALADA</i> la herramienta: SIEGE nivel de: VARIABLES DE ENTORNO. Esta herramienta permitirá <i>PROBAR</i> más adelante la aplicación del <i>RECURSO</i> : AUTOSCALING.	
• WINDOWS: siege-windows.zip	GMX+900996815@LAPTOP-PFBPUGRQ MINGW64 ~ (master) \$ siegeversion SIEGE 3.0.5
\$ siege –version • LINUX:	Copyright (C) 2013 by Jeffrey Fulmer, et al. This is free software; see the source for copying conditions. There is NO warranty; not even for MERCHANTABILITY or FITNESS FOR A PARTICULAR PURPOSE.
\$ sudo apt update -y \$ sudo apt install siege -y \$ siegeversion	
- <u>MAC</u> :	
\$ brew install siege \$ siegeversion	

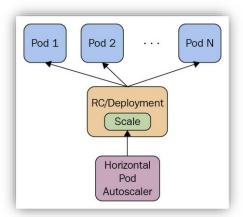
Cguerra@LAPTOP-PEBPUBERQ:-\$
cguerra@LAPTOP-PEBPUBERQ:-\$
cguerra@LAPTOP-PEBPUBERQ:-\$
in the configuration template added to /home/cguerra/.siege
Run siege -C to view the current settings in that file
SIEGE 4.0.4

Copyright (C) 2017 by Jeffrey Fulmer, et al.
This is free software; see the source for copying conditions.
There is NO warranty; not even for MERCHANTABILITY or FITNESS
FOR A PARTICULAR PURPOSE.

gianniguatame — -zsh — 80×24
gianniguatame@Giannis-MacBook-Pro - % siege —version
New configuration template added to /Users/gianniguatame/.siege
Run siege -C to view the current settings in that file
SIEGE 4.1.3

Copyright (C) 2022 by Jeffrey Fulmer, et al.
This is free software; see the source for copying conditions.
There is NO warranty; not even for MERCHANTABILITY or FITNESS
FOR A PARTICULAR PURPOSE.

2. ESCALAMIENTO DE 'CONTENEDORES':



El objetivo aquí es el poder CRECER a nivel de INSTANCIAS (PODs), para aplicarlos en los escenarios requeridos. Estos pueden ser: MANUÁLMENTE o AUTOMÁTICAMENTE.

A. SCALING INSTANCES:

Este procedimiento es el MANUAL & para ello se debe crear un **ESCENARIO** de prueba, corriendo el **Script** YAMEL:



Script_Microservicio .yaml

\$ cat > Script_Microservicio.yaml

\$ oc create -f Script_Microservicio.yaml

\$ oc get all -n dummy-csm<mark>-crga</mark>

```
$ cat > Script_Microservicio.yaml
#### ----- [NAMESPACE] ----- ####
apiVersion: v1
kind: Namespace
metadata:
 name: dummy-csm-crga
#### ----- [DEPLOYMENT] ----- ####
apiVersion: apps/v1
kind: Deployment
metadata:
 name: dummy-micro-deploy
  namespace: dummy-csm-crga
  labels:
   app: dummy-micro-service
   version: v1
spec:
  selector:
   matchLabels:
     app: dummy-micro-service
     version: v1
  template:
   metadata:
     labels:
       app: dummy-micro-service
   spec:
     containers:
     - image: maktup/dummy-micro-01:latest
       name: dummy-micro-container
       resources:
         limits:
          memory: 250Mi
         requests:
          cpu: 100m
           memory: 100Mi
       ports:
        - containerPort: 8080
#### ----- [SERVICE] ----- ####
```

```
$ oc create -f Script_Microservicio.yaml
namespace/dummy-csm-crga created
deployment.apps/dummy-micro-deploy created
service/dummy-micro-service created
route.route.openshift.io/dummy-micro-route created
$ oc get all -n dummy-csm-crga
                                      READY STATUS RESTARTS AGE
pod/dummy-micro-deploy-c54c7cf69-xs95l 1/1
                                              Running 0
                            TYPE
                                       CLUSTER-IP
                                                      EXTERNAL-IP PORT(S)
service/dummy-micro-service ClusterIP 172.21.30.139 <none>
                                                                    8080/TCP
                                                      AVAILABLE AGE
                                   READY UP-TO-DATE
deployment.apps/dummy-micro-deploy 1/1
                                            DESIRED CURRENT READY
                                                                      AGE
replicaset.apps/dummy-micro-deploy-c54c7cf69 1
                                          HOST/PORT
NAME
      PATH SERVICES
                                 PORT
                                         TERMINATION WILDCARD
route.route.openshift.io/dummy-micro-route
                                         dummy-micro-route-dummy-csm-crga.cluster-cla-crga-
loud
             dummy-micro-service <all>
```

Luego, se ingresa el **COMANDO** para el **AUMENTO MANUAL** hacia 5 **INSTANCIAS**:

\$ oc scale deployment dummy-micro-deploy --replicas=5 -n dummy-csm-crga

\$ oc get pods -n dummy-csm-crga

\$ oc scale deployment dummy-micro-deploy --replicas=5 -n dummy-csm-crga deployment.apps/dummy-micro-deploy scaled \$ oc get pods -n dummy-csm-crga READY STATUS RESTARTS AGE dummy-micro-deploy-c54c7cf69-2csfl Running 1/1 0 Running dummy-micro-deploy-c54c7cf69-h2rdr 1/1 0 11s dummy-micro-deploy-c54c7cf69-phrtj 1/1 Running 11s dummy-micro-deploy-c54c7cf69-rpmw8 1/1 Running 11s dummy-micro-deploy-c54c7cf69-xs951 1/1 Running 11m

Luego, se realiza una prueba del *MICROSERVICIO* desplegado. Los *REQUEST* enviados serán distribuidos a nivel de *TODAS* las *INSTANCIAS* desplegadas:

\$ curl http://dummy-micro-route-dummy-csm-crga.clustercla-crga-ccc03eca20d26e6ac64511f874a64b9b-0000.brsao.containers.appdomain.cloud/dummy-micro-01/qet/personas

```
GMX+000996815@LAPTOP-PFBPUGRQ MINGW64 ~ (master)
$ curl http://dummy-micro-route-dummy-csm-crga.cluster-cla-crga-ccc03eca20d26e6ac64511f874a64b9b-0000.br-sao.co
ntainers.appdomain.cloud/dummy-micro-01/get/personas

% Total % Received % Xferd Average Speed Time Time Time Current
Dload Upload Total Spent Left Speed

100 196 100 196 0 0 58 0 0:00:03 0:00:03 --:---- 60[{ 'nombre': 'PAOLO GUERRERO', 'e
dad': 35, 'rol': 'CONSULTOR' },{ 'nombre': 'LUIS GUADALUPE', 'edad': 40, 'rol': 'PROGRAMADOR' },{ 'nombre': 'PEDRO SALAZAR', 'edad': 30, 'rol': 'ARQUITECTO' }]
```

Finalmente, para el **DECREMENTO MANUAL** de **INSTANCIAS** hacia: 1 (dejarlo como estaba inicialmente), se ingresa:

\$ oc scale deployment dummy-micro-deploy --replicas=1 -n dummy-csm-crga

\$ oc get pods -n dummy-csm-crga

```
$ oc scale deployment dummy-micro-deploy --replicas=1 -n dummy-csm-crga
deployment.apps/dummy-micro-deploy scaled
$ oc get pods -n dummy-csm-crga
NAME
                                   READY
                                         STATUS
                                                        RESTARTS AGE
dummy-micro-deploy-c54c7cf69-2csfl
                                  0/1
                                           Terminating
                                                                   10m
dummy-micro-deploy-c54c7cf69-h2rdr 1/1
                                           Running
                                                        0
                                                                   10m
dummy-micro-deploy-c54c7cf69-phrtj 0/1
                                           Terminating
                                                       0
                                                                   10m
dummy-micro-deploy-c54c7cf69-rpmw8 0/1
                                          Terminating
                                                                   10m
dummy-micro-deploy-c54c7cf69-xs95l 0/1
                                          Terminating
                                                                   21m
$ oc get pods -n dummy-csm-crga
                                         STATUS RESTARTS
                                   READY
                                                              AGE
dummy-micro-deploy-c54c7cf69-h2rdr
                                          Running 0
                                                               13m
```

B. HORIZONTAL AUTOSCALING INSTANCES:

El objetivo aquí es el poder CRECER a nivel de INSTANCIAS (PODs), esto aplicado en los escenarios de TRÁFICO CAMBIANTE, sobre todo, pero de manera: AUTOMÁTICA.

<u>IMPORTANTE</u>: "Antes que nada, se debe conocer que el **HORIZONTAL AUTOSCALING**, requiere que esté **ACTIVO** algo que se llama: **METRIC-SERVER**, esto sirve para poder desde **OPENSHIFT** medir el control **CPU & MEMORIA** tanto a nivel de: **NODOS & PODs** respectivamente.

En **KUBERNETES** no está instalado, pero si en **OPENSHIFT** (**NO se requiere**)":

\$ git clone https://github.com/kodekloudhub/kubernetes-metrics-server.git

\$ cd kubernetes-metrics-server

\$ oc create -f ./

Luego, para **PROBAR** este escenario se requiere ejecutar los **COMANDOS IMPERATIVOS** siguientes:

\$ oc autoscale deployment dummy-micro-deploy --min=1 -max=4 --cpu-percent=40 -n dummy-csm-crga

\$ oc get pods,hpa -o wide -n dummy-csm-crga

<u>IMPORTANTE</u>: "Esta modalidad a nivel de **COMANDOS**, aplica una **REGLA** que funciona solo a nivel de **CPU**".

```
$ oc autoscale deployment dummy-micro-deploy --min=1 --max=4 --cpu-percent=40 -n dummy-csm-crga
horizontalpodautoscaler.autoscaling/dummy-micro-deploy autoscaled
$ oc get pods,hpa -o wide -n dummy-csm-crga
                                       READY
                                                       RESTARTS
                                                                 AGE IP
pod/dummy-micro-deploy-c54c7cf69-h2rdr
                                      1/1
                                               Running
                                                                   26m
                                                                       172.30.240.218 10.150.181.189
                                                                                                         <none:
                                                      REFERENCE
                                                                                     TARGETS MINPODS
                                                                                                        MAXPODS
horizontalpodautoscaler.autoscaling/dummy-micro-deploy Deployment/dummy-micro-deploy
                                                                                    3%/40%
```

Luego, es necesario obtener el **ROUTE** creado del *MICROSERVICIO*, ejecutando:

\$ oc get routes -n dummy-csm-crga

```
GNX+000996815@LAPTOP-PFBPUGRQ MINGW64 ~ (master)

$ oc get routes -n dummy-csm-crga

NAME HOST/PORT
PATH SERVICES

dummy-micro-route | dummy-nicro-route-dummy-csm-crga.cluster-cla-crga-ccc03eca20d26e6ac64511f874a64b9b-0000.br-sao.containers.appdomain.cloud

dummy-micro-service <all>
None
```

Luego, se requiere probar **MASIVAMENTE** contra el **MICROSERVICIO** desplegado. Así mismo, los **REQUEST** serán distribuidos a nivel de **TODAS** las **INSTANCIAS** desplegadas y/o se vayan **ACTIVANDO**:

SIEGE permitirá enviar *REQUEST* de manera *PARALELA*, esto significa que en la demostración se enviarán: **4 PETICIONES**, cada una con **20 CONCURRENCIAS** (en **TOTAL** se deberán ejecutar: **80 Mensajes**).

\$ siege --concurrent=20 --reps=4 -v http://dummy-microroute-dummy-csm-crga.cluster-cla-crgaccc03eca20d26e6ac64511f874a64b9b-0000.ussouth.containers.appdomain.cloud/dummy-micro-01/qet/personas

IMPORTANTE: "La ejecución del TRÁFICO MASIVO hará que el CPU, como se muestra la IMAGEN, se incremente & genere la ELASTICIDAD a nivel de INSTANCIAS de PODs".

\$ oc get pods,hpa -n dummy-csm-crga

(VERSIÓN LINUX)

. . gianniguatame — -zsh — 80×66 gianniguatame@Giannis-MacBook-Pro ~ % siege --concurrent=20 --reps=4 -v http:// dummy-micro-route-dummy-csm-crga.cluster-cla-crga-ccc03eca20d26e6ac64511f874a64 b-0000.br-sac.containers.appdomain.cloud/dummy-micro-01/get/personas ** SIEGE 4.1.3 ** Preparing 20 concurrent users for battle. The server is now under siege... HTTP/1.1 200 0.90 secs: 196 bytes ==> GET /dummy-micro-01/get/personas HTTP/1.1 200 1.00 secs: 196 bytes ==> GET /dummy-micro-01/get/personas HTTP/1.1 200 1.10 secs: 196 bytes ==> GET /dummy-micro-01/get/personas HTTP/1.1 200 1.10 secs: 196 bytes ==> GET /dummy-micro-01/get/personas HTTP/1.1 200 196 bytes ==> GET /dummy-micro-01/get/personas 1.10 secs: HTTP/1.1 200 196 bytes ==> GET /dummy-micro-01/get/personas 1.20 secs: 196 bytes ==> GET /dummy-micro-01/get/personas HTTP/1.1 200 1,20 secs: HTTP/1.1 200 196 bytes ==> GET /dummy-micro-01/get/personas 1.20 secs: HTTP/1.1 200 196 bytes --> GET /dummy-micro-01/get/personas 1.28 secsi HTTP/1.1 200 196 bytes ==> GET /dummy-micro-01/get/personas 1.28 secs: HTTP/1.1 200 196 bytes ==> GET /dummy-micro-01/get/personas 1.28 secs: HTTP/1.1 200 1.20 secs: 196 bytes ==> GET /dummy-micro-01/get/personas HTTP/1.1 200 0.40 secs: 196 bytes ==> GET /dummy-micro-01/get/personas HTTP/1.1 200 1.30 secs: 196 bytes ==> GET /dummy-micro-01/get/personas HTTP/1.1 200 1.40 secs: 196 bytes ==> GET /dummy-micro-01/get/personas

(VERSIÓN MAC)

Luego, se debe verificar que después de un **TIEMPO** de realizada la **PRUEBA** de: **REQUEST MASIVOS**, la plataforma se debe haber estabilizado a nivel de **CPU**. (La **ELIMINACIÓN** de los **PODs** adicionales es **AUTOMÁTICA**).

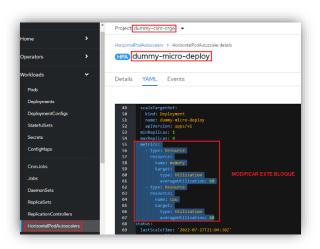
\$ oc get pods,hpa -n dummy-csm-crga

Finalmente, solo para **COMPLEMENTAR** que la modalidad en *SCRIPT* del: **HORIZONTAL AUTOSCALING**, **NO** solamente funciona a nivel de *CPU*, sino que también funciona *SIMULTÁNEAMENTE* a nivel de *MEMORIA*.

"Esto vuelve más **SENSIBLE** la activación del: **HORIZONTAL AUTOSCALING**".

apiVersion: autoscaling/v2beta2 kind: HorizontalPodAutoscaler metadata: name: dummy-micro-deploy namespace: dummy-csm-crga spec: scaleTargetRef: apiVersion: apps/v1 kind: Deployment name: dummy-micro-deploy

minReplicas: 1 maxReplicas: 4 metrics: - type: Resource

resource: name: cpu 

target:
 type: Utilization
 averageUtilization: 40

- type: Resource
 resource:
 name: memory
 target:
 type: Utilization
 averageUtilization: 60

\$ oc get pods,hpa -n dummy-csm<mark>-crga</mark>

IMPORTANTE: "Se aprecia como la REGLA del HORIZONTAL AUTOSCALING, ahora está aplicara a nivel de: CPU & MEMORIA".

